

L'ANALYSE FACTORIELLE

1. INTRODUCTION

Les deux grandes familles d'outils statistiques

Les **statistiques inférentielles**, visant à expliquer une ou des mesures par un ensemble de facteurs. Il s'agit des **tests statistiques**.

Les **statistique descriptives**, visant à structurer et résumer l'information : **l'analyse factorielle** en fait partie. N'étant pas des tests, ces méthodes n'ont pas de condition de distribution (telle que la normalité). Par exemple, on peut toujours calculer une moyenne, une médiane ...

Mais que faire face à ça :

	NH4	NOx	Si	PO4	BCR	GPP	PP	BB	MaB	MeB	Chla	Temp	median
SA1	148	44	125.8	15.7	0.00	13.8	0.5	16.5	15548	1849	28.96	8.30	64.70
SA2	139	8	85.0	20.2	2.55	7.6	0.2	19.1	11931	2863	30.57	13.70	87.37
SA3	105	3	66.7	4.4	6.51	14.1	0.6	29.1	20263	2329	23.43	16.10	161.17
SA4	109	2	84.0	6.6	3.56	9.5	0.4	33.2	18604	716	26.70	19.00	100.37
SA5	139	0	212.3	7.7	3.40	10.2	0.3	35.5	21473	2578	31.67	17.70	141.94
SA6	76	13	63.0	4.7	9.63	22.4	0.8	25.7	24107	1471	28.40	23.30	183.01
SA7	44	9	35.9	3.0	7.42	22.4	0.8	20.4	6731	1451	29.68	18.25	230.58
SA8	133	1	136.5	7.8	9.45	24.8	0.4	37.0	21418	1500	61.63	22.15	87.37
SA9	223	2	184.6	10.8	5.98	13.2	0.2	27.6	29290	1729	63.62	14.20	70.15
SA10	132	6	93.4	7.2	1.62	7.9	0.2	24.7	20458	1757	37.78	7.30	126.45
SA11	55	8	79.6	4	1.44	9.9	0.4	27.9	9854	1899	23.54	10.60	125.00
SB2	81	6	31.7	4.5	0.00	7.8	0.4	8.4	8570	1265	19.31	16.40	183.01
SB3	43	0	17.3	1.0	0.48	7.6	0.5	14.7	9158	1879	15.27	17.70	222.72
SB4	49	0	25.3	2.7	0.00	14.2	0.7	13.7	1642	685	19.74	19.10	238.71
SB5	114	0	88.0	9.0	3.03	12.9	0.6	18.9	7945	1256	23.36	19.60	180.91
SB6	31	13	41.2	3.8	3.55	17.2	0.9	24.3	4079	1163	18.11	23.10	191.67
SB7	25	16	32.3	2.9	5.33	20.8	1.2	27.0	2537	1211	17.89	22.30	235.97
SB8	24	4	28.8	2.7	0.96	26.6	0.7	27.9	792	1604	38.91	19.60	274.21
SB9	30	1	28.8	3.8	0.62	21.4	0.6	10.7	6680	1200	35.22	17.15	244.29
SB10	70	2	40.2	5.5	0.95	21.0	0.4	19.9	4192	1774	47.93	10.90	191.67
SB11	69	4	20.1	5.75	0.00	10.0	0.8	12.6	3697	905	12.92	14.60	189.46
SC2	17	8	2.0	2.0	0.00	6.1	0.7	4.2	2475	265	8.69	9.20	238.71
SC3	7	0	20.3	0.0	0.00	5.4	0.5	3.2	2515	274	12.00	15.40	238.71
SC4	6	0	4.0	0.0	0.00	3.6	0.3	10.2	1041	266	10.44	18.10	247.13
SC5	9	0	4.7	0.0	0.00	6.2	0.6	11.2	1831	274	9.59	14.80	258.82
SC6	9	0	8.0	0.5	1.18	5.0	0.6	7.5	1207	508	9.02	19.45	250.00
SC7	10	8	19.8	2.9	2.01	9.6	0.6	22.0	1583	564	15.91	22.30	252.90
SC8	20	5	9.9	2.4	0.00	10.7	0.7	12.2	1176	638	16.12	16.70	258.82
SC9	23	4	8.8	2.9	0.00	9.2	0.5	5.9	1234	671	18.82	15.30	258.82
SC10	17	3	3.9	1.7	0.00	4.3	0.2	6.1	800	253	18.04	11.90	267.94
SC11	0	4	8.5	0.9	0.00	5.8	0.5	7.9	78	218	11.61	14.00	244.29

On ne peut rien tirer de ces données par la simple observation.


Analyser des graphiques serait très fastidieux et peu informatif.

De plus, il est probable que certaines de ces données soient corrélées, et donc redondantes.


Solution : l'analyse factorielle

Identification de groupes de variables associées entre elles

Variables – PCA




Variables – PCA



Solution : l'analyse factorielle

Identification d'individus associés, repérage de extrêmes, visualisation de facteurs ...

Individuals - PCA



Solution : l'analyse factorielle

L'objectif principal des analyses descriptives multivariées est d'étudier ou de décrire un ensemble de variables prises *globalement*.

Les techniques d'**analyse factorielle** permettent de *synthétiser* et de *visualiser* rapidement une grande quantité d'information.

- On obtient une nouvelle **représentation visuelle** selon les **nouveaux axes factoriels**, qui devront faire perdre le moins d'information possible.
- Ces axes factoriels sont en fait tout simplement de nouvelles variables résumant celles dont vous êtes parti.

- **Buts** = simplifier la vision des données (réduire leur dimensionalité) pour en assurer leur interprétation : passer d'un espace multidimensionnel à un espace comprenant moins de dimensions (2 voire 3), en perdant le moins d'information possible ; dégager les tendances principales de la variabilité des données

On recherche concrètement trois types d'informations :

- Relations entre les variables
- Relations / Ressemblances entre les individus
- Relations entre variables et individus

Un exemple d'analyse factorielle : l'Analyse en Composante Principale (ACP)

Objectif : On va réduire à quelques variables (appelées **composantes principales**) les variables étudiées, et utiliser ces composantes principales pour trier / regrouper les individus statistiques et interpréter les données.


2. LES DONNEES

- Il existe plusieurs packages, nous allons travailler avec
 - ade4 pour conduire l'analyse
 - factoextra pour la représentation des résultats
- Exemple pris : jeu de données **meaudret** inclus dans le package ade4
24 séries de 10 mesures
(6 stations de prélèvement dans un baie * 4 saisons)

```
# chargement de la librairie ade4
library(ade4)
library(factoextra)

# chargement du jeu de données "meau"
data(meau)
TAB1 = meau$env
TAB1 # le tableau de données
meau$design # sites et saisons
```

- Température, Courant, pH, Conductivité, Oxygène, Demande biologique en oxygène sur 5 jours (DBO5), Matières oxydées, Ammonium, Nitrate, Phosphate
= 10 variables, chacune sur une colonne du tableau
- 6 stations prélevées * 4 saisons (sp = spring, etc ...)
= 24 mesures (ou individus), chacun sur une ligne du tableau



Que faire de toutes ces données ?

- Calculer les 10 moyennes n'apporte pas grand-chose


```
summary(TAB1)
```

```
Console ~/Cours/M1 Statistiques S1/
> summary(TAB1)
```

Temp	Flow	pH	Cond	Oxyg	Bdo5	Oxyd	Ammo	Nitr	Phos
Min. : 1.000	Min. : 25.00	Min. : 7.600	Min. : 245.0	Min. : 13.00	Min. : 1.300	Min. : 0.500	Min. : 0.0400	Min. : 0.800	Min. : 0.0300
1st Qu.: 3.000	1st Qu.: 79.75	1st Qu.: 8.175	1st Qu.: 290.0	1st Qu.: 83.50	1st Qu.: 1.700	1st Qu.: 1.200	1st Qu.: 0.1175	1st Qu.: 2.925	1st Qu.: 0.1825
Median : 7.000	Median : 159.00	Median : 8.300	Median : 325.0	Median : 100.00	Median : 3.400	Median : 1.600	Median : 0.4650	Median : 4.200	Median : 0.8300
Mean : 7.708	Mean : 196.33	Mean : 8.271	Mean : 325.0	Mean : 87.67	Mean : 6.717	Mean : 2.083	Mean : 2.1204	Mean : 5.198	Mean : 1.5504
3rd Qu.: 13.000	3rd Qu.: 304.75	3rd Qu.: 8.500	3rd Qu.: 352.5	3rd Qu.: 101.25	3rd Qu.: 8.550	3rd Qu.: 2.525	3rd Qu.: 2.7250	3rd Qu.: 6.725	3rd Qu.: 2.0175
Max. : 16.000	Max. : 498.00	Max. : 8.600	Max. : 425.0	Max. : 126.00	Max. : 36.000	Max. : 8.000	Max. : 12.5000	Max. : 13.200	Max. : 6.5000

- Regarder les corrélations 2 à 2 non plus : Fonction *ggpairs* (package *Ggally*)

```
ggpairs(TAB1, diag = list(continuous = "blankDiag")) # sans la diagonale
```



Cependant,
on note que certaines variables
sont corrélées (redondance)

Que faire de toutes ces données ?

- Calcul des covariances et des corrélations

```
cov(TAB1) # matrice des covariances (= variation commune de deux variables)
```

```
cor(TAB1) # matrice des corrélations (= covariance normalisée entre -1 et 1)
```

Console ~/Cours/M1 Statistiques S1/ ↗

```
> cov(TAB1) # la matrice des covariances
```

	Temp	Flow	pH	Cond	Oxyg	Bdo5	Oxyd	Ammo	Nitr	Phos
Temp	28.4764493	-79.855072	-0.17409420	-17.608696	-33.666667	3.870290	0.9818841	2.5749094	-2.02833333	0.5640399
Flow	-79.8550725	19101.101449	6.63188406	-1863.913043	1434.289855	-281.518841	-61.1855072	-144.3557971	-129.80811594	-77.7792754
pH	-0.1740942	6.631884	0.06563406	-7.652174	5.128986	-1.307319	-0.2552899	-0.6444221	0.06551449	-0.2822917
Cond	-17.6086957	-1863.913043	-7.65217391	1739.130435	-695.217391	252.282609	53.4782609	113.5847826	23.68260870	60.7347826
Oxyg	-33.6666667	1434.289855	5.12898551	-695.217391	860.753623	-163.528986	-35.0927536	-76.1785507	13.85246377	-32.2955072
Bdo5	3.8702899	-281.518841	-1.30731884	252.282609	-163.528986	63.879710	12.6889855	26.0306449	-5.19144928	11.9112971
Oxyd	0.9818841	-61.185507	-0.25528986	53.478261	-35.092754	12.688986	2.8118841	5.1810072	-1.37768116	2.3239203
Ammo	2.5749094	-144.355797	-0.64442210	113.584783	-76.178551	26.030645	5.1810072	11.4369694	-1.45252971	5.2375520
Nitr	-2.0283333	-129.808116	0.06551449	23.682609	13.852464	-5.191449	-1.3776812	-1.4525297	10.79397971	1.2794268
Phos	0.5640399	-77.779275	-0.28229167	60.734783	-32.295507	11.911297	2.3239203	5.2375520	1.27942681	2.9017781

```
> cor(TAB1) # la matrice des corrélations
```

	Temp	Flow	pH	Cond	Oxyg	Bdo5	Oxyd	Ammo	Nitr	Phos
Temp	1.00000000	-0.1082755	-0.12734349	-0.07912581	-0.21503927	0.09074425	0.1097283	0.1426802	-0.11569261	0.0620490
Flow	-0.10827555	1.00000000	0.18730229	-0.32339281	0.3537271	-0.25485713	-0.2640102	-0.3088514	-0.28587873	-0.3303715
pH	-0.12734349	0.1873023	1.00000000	-0.71623267	0.6823818	-0.63846254	-0.5942514	-0.7437900	0.07783626	-0.6468466
Cond	-0.07912581	-0.3233928	-0.71623267	1.00000000	-0.5682182	0.75690220	0.7647377	0.8053758	0.17285131	0.8549472
Oxyg	-0.21503927	0.3537271	0.68238177	-0.56821817	1.00000000	-0.69738700	-0.7133116	-0.7677818	0.14371324	-0.6462054
Bdo5	0.09074425	-0.2548571	-0.63846254	0.75690220	-0.6973870	1.00000000	0.9467749	0.9630481	-0.19770441	0.8748740
Oxyd	0.10972828	-0.2640102	-0.59425141	0.76473769	-0.7133116	0.94677488	1.00000000	0.9136083	-0.25006863	0.8135616
Ammo	0.14268015	-0.3088514	-0.74378997	0.80537583	-0.7677818	0.96304810	0.9136083	1.00000000	-0.13073105	0.9091609
Nitr	-0.11569261	-0.2858787	0.07783626	0.17285131	0.1437132	-0.19770441	-0.2500686	-0.1307310	1.00000000	0.2286086
Phos	0.06204900	-0.3303715	-0.64684665	0.85494722	-0.6462054	0.87487396	0.8135616	0.9091609	0.22860859	1.00000000

En lignes et en colonnes : les variables

Dans les cases : les covariances / corrélations

Sur la diagonale :

- cov(TAB1) : covariance des variables avec elles-mêmes = **variance**
- cor(TAB1) : corrélation des variables avec elles-mêmes = **1**

Que faire de toutes ces données ?

- Les tableaux de résultat covariance/corrélation sont identiques après la normalisation (la corrélation est bien une normalisation de la covariance)
 - La covariance des variables centrées/réduites : `cov(TAB1norm)` correspond à la corrélation de ces mêmes variables : `cor(TAB1)`

```
cov(TAB1norm)
```

```
cor(TAB1norm)
```

```
> cov(TAB1norm)
```

	Temp	Flow	pH	Cond	Oxyg	Bdo5	Oxyd	Ammo	Nitr	Phos
Temp	1.00000000	-0.1082755	-0.12734349	-0.07912581	-0.2150393	0.09074425	0.1097283	0.1426802	-0.11569261	0.0620490
Flow	-0.10827555	1.00000000	0.18730229	-0.32339281	0.3537271	-0.25485713	-0.2640102	-0.3088514	-0.28587873	-0.3303715
pH	-0.12734349	0.1873023	1.00000000	-0.71623267	0.6823818	-0.63846254	-0.5942514	-0.7437900	0.07783626	-0.6468466
Cond	-0.07912581	-0.3233928	-0.71623267	1.00000000	-0.5682182	0.75690220	0.7647377	0.8053758	0.17285131	0.8549472
Oxyg	-0.21503927	0.3537271	0.68238177	-0.56821817	1.00000000	-0.69738700	-0.7133116	-0.7677818	0.14371324	-0.6462054
Bdo5	0.09074425	-0.2548571	-0.63846254	0.75690220	-0.6973870	1.00000000	0.9467749	0.9630481	-0.19770441	0.8748740
Oxyd	0.10972828	-0.2640102	-0.59425141	0.76473769	-0.7133116	0.94677488	1.00000000	0.9136083	-0.25006863	0.8135616
Ammo	0.14268015	-0.3088514	-0.74378997	0.80537583	-0.7677818	0.96304810	0.9136083	1.00000000	-0.13073105	0.9091609
Nitr	-0.11569261	-0.2858787	0.07783626	0.17285131	0.1437132	-0.19770441	-0.2500686	-0.1307310	1.00000000	0.2286086
Phos	0.06204900	-0.3303715	-0.64684665	0.85494722	-0.6462054	0.87487396	0.8135616	0.9091609	0.22860859	1.0000000

```
> cor(TAB1norm)
```

	Temp	Flow	pH	Cond	Oxyg	Bdo5	Oxyd	Ammo	Nitr	Phos
Temp	1.00000000	-0.1082755	-0.12734349	-0.07912581	-0.2150393	0.09074425	0.1097283	0.1426802	-0.11569261	0.0620490
Flow	-0.10827555	1.00000000	0.18730229	-0.32339281	0.3537271	-0.25485713	-0.2640102	-0.3088514	-0.28587873	-0.3303715
pH	-0.12734349	0.1873023	1.00000000	-0.71623267	0.6823818	-0.63846254	-0.5942514	-0.7437900	0.07783626	-0.6468466
Cond	-0.07912581	-0.3233928	-0.71623267	1.00000000	-0.5682182	0.75690220	0.7647377	0.8053758	0.17285131	0.8549472
Oxyg	-0.21503927	0.3537271	0.68238177	-0.56821817	1.00000000	-0.69738700	-0.7133116	-0.7677818	0.14371324	-0.6462054
Bdo5	0.09074425	-0.2548571	-0.63846254	0.75690220	-0.6973870	1.00000000	0.9467749	0.9630481	-0.19770441	0.8748740
Oxyd	0.10972828	-0.2640102	-0.59425141	0.76473769	-0.7133116	0.94677488	1.00000000	0.9136083	-0.25006863	0.8135616
Ammo	0.14268015	-0.3088514	-0.74378997	0.80537583	-0.7677818	0.96304810	0.9136083	1.00000000	-0.13073105	0.9091609
Nitr	-0.11569261	-0.2858787	0.07783626	0.17285131	0.1437132	-0.19770441	-0.2500686	-0.1307310	1.00000000	0.2286086
Phos	0.06204900	-0.3303715	-0.64684665	0.85494722	-0.6462054	0.87487396	0.8135616	0.9091609	0.22860859	1.0000000

3. CALCUL DE L'ACP

Que permet de faire l'ACP ?

- L'ACP se calcule sur la **matrice des corrélations**, c'est-à-dire les covariances normalisées
- C'est une **projection** de données en p dimensions (p =nombre de variables) en 2 ou 3 dimensions indépendantes qui gardent l'essentiel de l'information (analogie avec une ombre).
- Transformations linéaires (seulement les 4 opérations) d'un grand nombre de variables inter-corrélées de manière à obtenir un nombre faible de **composantes principales** (ou axes) non corrélées (indépendantes donc non redondantes) mais **reliées aux variables d'origine** et **indépendantes entre elles** (non corrélées)
- R le fait automatiquement, mais nous allons détailler le principe du calcul

Les composantes principales

Rappel : utilité des composantes principales dans l'ACP

- Indiquer comment les **variables** sont **associées**
- Indiquer comment on peut **regrouper** les **individus**
- Indiquer les **associations individus/variables**

Comment les obtenir ?

- Version concise : ce sont les **valeurs propres** de la matrice des corrélations
- Qu'est-ce que ça veut dire ?


Principe de l'ACP

A partir du tableau de données, on calcule la **matrice des covariances** : tableau montrant la covariance de chaque variable avec toutes les autres.

Les variances sont sur la diagonale ; la matrice est symétrique par rapport à la diagonale.

	V1	V2	V3	...
V1	Varianc V1	1,895	45,786	...
V2	1,895	Varianc V2	-45,12	...
V3	45,786	-45,12	Varianc V3	...
...	...	...	...	...

Variance totale



La trace (somme de la diagonale) est la somme de toute les variances, ou variance totale.

Pour p variables on a une matrice de dimensions $p \times p$; matrice carrée, p éléments sur sa diagonale.

Principe de l'ACP

On travaille sur la matrice des **coefficients de corrélation** (= covariance sur les données normalisées).

Éléments de la diagonale = 1 (corrélation d'une variable avec elle-même).

Avec p variables, on a p éléments sur la diagonale donc la variance totale (trace) vaut p (car $p * 1 = p$).

	V1	V2	V3	...
V1	1	0,86	0,45	...
V2	0,86	1	-0,75	...
V3	0,45	-0,75	1	...
...	...	...	...	...

Principe de l'ACP

2 notions importantes d'algèbre matriciel :

- Les matrices carrées de dimension p peuvent être décomposées en **p valeurs propres**, chacune associée à un **vecteur propre** (*en anglais et en allemand : eigen values et eigen vectors*). Les logiciels font automatiquement ce calcul fastidieux. Les valeurs propres sont parfois appelées inertie.
- La **somme des valeurs propres est égale à la trace** (somme de la diagonale) : autrement dit, la variance totale est décomposée en p valeurs propres.

Concrètement :

- S'il y a p variables corrélées entre elles, l'ACP les transforme en p composantes principales indépendantes (= non corrélées). **La variance (ou part d'information) portée par chaque composante est la valeur propre correspondante.**
- **La variance totale est répartie entre les composantes principales, de façon non homogène : la plupart des composantes conservent très peu de variance, et souvent les 2 ou 3 premières vont garder l'essentiel de la variance. On a réduit nos p données redondantes à 2 ou 3 composantes principales indépendantes.**
- **Les vecteurs propres permettent de calculer les composantes principales et d'y placer chaque individu.** En effet, ces vecteurs sont des combinaisons linéaires des variables d'origine.
- Cela revient à projeter nos données à p dimensions en 2 ou 3 dimensions seulement (principe de l'ombre).

Principe de l'ACP : les vecteurs propres

Les vecteurs propres servent à construire les composantes principales à partir des anciennes variables.

Chaque individu a une valeur pour chaque composante principale, cette valeur est calculée à partir des variables d'origine et du vecteur propre de la composante en question

	Variable 1	Variable 2	Variable 3	Composante principale 1	Composante Principale 2	Composante principale 3
Individu 1	2	4	-5	-12	27	6
Individu 2	4,5	4	4	8,5	25,5	13,75
Individu 3	-3	2	3	1	-4	10,5
Vecteurs propres				1	3	-0,5
				-1	4	3
				2	-1	1

C'est bien un calcul linéaire

$$\left\{ \begin{array}{l} 2*1 + 4*(-1) + (-5)*2 = -12 \\ 4,5*3 + 4*4 + 4*(-1) = 25,5 \end{array} \right.$$

4. APPLICATION À NOTRE EXEMPLE

```
# Déterminer les composantes principales
VP = eigen(cor(TAB1)) # Valeurs et vecteurs propres de la matrice de
corrélation de TAB1
VP
```

Console ~/Cours/M1 Statistiques S1/ ↗

```
> VP=eigen(cor(TAB1))
> VP
$values
[1] 5.74507074 1.43012514 1.08378050 0.67612450 0.52437243 0.30331538 0.14623672 0.05370575 0.02273369 0.01453517


$vectors
      [,1]      [,2]      [,3]      [,4]      [,5]      [,6]      [,7]      [,8]      [,9]     [,10]
[1,] 0.05607644 -0.27113001 0.82111983 0.415660867 -0.20106725 0.141659344 -0.11366474 0.02836034 -0.03799130 0.02587452
[2,] -0.15864457 -0.43052909 -0.46928359 0.695376909 -0.07355322 -0.260389358 -0.09152789 -0.01225317 -0.04396748 -0.04502368
[3,] -0.32902700 0.05489709 0.01336907 -0.277525316 -0.71541723 -0.342914204 -0.29251186 0.29745513 -0.06337484 -0.06369806
[4,] 0.36242550 0.22150860 -0.19548413 0.140963912 0.03881721 0.380244027 -0.68785372 0.32630662 -0.18354978 0.04577404
[5,] -0.33966674 0.11161422 -0.19124179 0.134115849 -0.40176198 0.753537115 0.26041646 -0.10556525 0.06527154 -0.07180732
[6,] 0.39291475 -0.12085896 -0.10212564 -0.068394094 -0.30870045 -0.011128239 0.31488873 -0.10690948 -0.67374492 0.39492675
[7,] 0.38479142 -0.15568153 -0.08016634 -0.141845428 -0.31509721 -0.004245594 -0.29811155 -0.70454652 0.29447754 -0.17284230
[8,] 0.40805412 -0.07071282 -0.02845027 0.008806172 -0.11175656 -0.005158840 0.31098573 0.32542886 -0.05838935 -0.78042491
[9,] -0.02370013 0.76966283 0.09223464 0.403757745 -0.06842488 -0.264439300 0.04057954 -0.30321017 -0.20056782 -0.16464881
[10,] 0.38364897 0.20092521 -0.06630233 0.202245069 -0.26012864 -0.109724828 0.25650746 0.29544911 0.60858052 0.40494507

>
```


4. APPLICATION À NOTRE EXEMPLE

Graphique des éboulis, ou scree plot : les valeurs propres (en Y) en fonction des composantes principales (en X) classées par ordre décroissant


```
barplot(VP$values)  
abline(h = mean(VP$values)) # Droite horizontale à la moyenne des VP
```



Combien garde t-on de composante principales (valeurs propres) ?



Combien garde t-on de valeurs propres ?



Attention ! Les critères de Cattell et de Kaiser sont commodes, mais loin d'être parfaits ...

Combien garde t-on de valeurs propres ?

On calcule la **part de variance expliquée par la combinaison des composantes**.

```
CP = VP$values/sum(VP$values) # proportion de variance expliquée par chaque CP  
CP
```

```
> CP = VP$values / sum(VP$values)
```

```
> CP # Proportions
```

```
[1] 0.574507074 0.143012514 0.108378050 0.067612450 0.052437243 0.030331538 0.014623672 0.005370575 0.002273369 0.001453517
```

Combien garde t-on de valeurs propres ?

On calcule la **part de variance expliquée par la combinaison des composantes**.

```
CP = VP$values/sum(VP$values) # proportion de variance expliquée par chaque CP
CP
CP*100 # en % de variance expliquée
```

```
> CP = VP$values / sum(VP$values)
> CP # Proportions
[1] 0.574507074 0.143012514 0.108378050 0.067612450 0.052437243 0.030331538 0.014623672 0.005370575 0.002273369 0.001453517
> CP*100 # En % de variance expliquée
[1] 57.4507074 14.3012514 10.8378050 6.7612450 5.2437243 3.0331538 1.4623672 0.5370575 0.2273369 0.1453517
```

1^{ère} valeur propre = 57,45% de l'information totale
 2^{ème} valeur propre = 14,30% de l'information totale
 etc ...

Combien garde t-on de valeurs propres ?

On calcule la **part de variance expliquée par la combinaison des composantes**.

```
CP = VP$values/sum(VP$values) # proportion de variance expliquée par chaque CP
CP
```

```
CP*100 # en % de variance expliquée
cumsum(CP*100) # somme cumulée
```

```
> CP = VP$values / sum(VP$values)
> CP # Proportions
[1] 0.574507074 0.143012514 0.108378050 0.067612450 0.052437243 0.030331538 0.014623672 0.005370575 0.002273369 0.001453517
> CP*100 # En % de variance expliquée
[1] 57.4507074 14.3012514 10.8378050 6.7612450 5.2437243 3.0331538 1.4623672 0.5370575 0.2273369 0.1453517
> cumsum(CP*100) # somme cumulée
[1] 57.45071 71.75196 82.58976 89.35101 94.59473 97.62789 99.09025 99.62731 99.85465 100.00000
```

❖ **Pourcentage de variance (ou d'inertie) cumulé pour chaque CP (*proportion cumulée de leurs valeurs propres*)**

Pour les deux premières CP : $[(5,745+1,430)/10]*100 = 71,75\%$

→ plus de 70% de la variance de la matrice d'origine est expliquée par les deux composantes CP1 et CP2


❖ Empiriquement, on est très satisfait quand on parvient à expliquer **au moins 80% des données avec 2 variables, au plus 3**

Dans notre exemple, on atteint plus de 80% avec 3 composantes

Une ACP qui a besoin de 5 variables pour expliquer 40% des données est plus difficile à interpréter

Avec R :

```
ACP = dudi.pca(TAB1) # la fonction dudi.pca se charge de prendre la matrice des
corrélations
# ATTENTION ! La fonction affiche le graphique des éboulis et attend que vous
donniez le nombre de composantes à extraire
# Ici, choisissez 3 ; vous pouvez aussi la relancer avec plus ou moins de
composantes
ACP
# ACP$eig les valeurs propres
# ACP$li les nouvelles coordonnées des individus
# ACP$co les nouvelles coordonnées des variables (loading matrix)
# D'autres paramètres sont présents, ils ne nous sont pas utiles
```



Question typique d'examen

Critère de Kaiser
Critère du coude
Critère des 80%
 (On en prend au moins 2)

Avec R :

La fonction summary sur ACP permet de retrouver l'informations sur les valeurs propres, pour le critère des 80% :

```
summary(ACP)
```

```
> summary(ACP)
```

```
Class: pca dudi
```

```
Call: dudi.pca(df = TAB1)
```

```
Total inertia: 10
```

```
Eigenvalues:
```

Ax1	Ax2	Ax3	Ax4	Ax5
5.7451	1.4301	1.0838	0.6761	0.5244

```
Projected inertia (%):
```

Ax1	Ax2	Ax3	Ax4	Ax5
57.451	14.301	10.838	6.761	5.244


```
Cumulative projected inertia (%):
```

Ax1	Ax1:2	Ax1:3	Ax1:4	Ax1:5
57.45	71.75	82.59	89.35	94.59

```
(Only 5 dimensions (out of 10) are shown)
```

Avec R :

```
# La fonction fviz_eig( ) du package factextra permet de retracer le graphique  
des valeurs propres pour le critère de Kaiser et le critère de Catell :  
fviz_eig(ACP)
```



5. QU'EN DEDUIT-ON ?

Rappel : utilité des composantes principales dans l'ACP


- Indiquer comment les **variables** sont **associées**
- Indiquer comment on peut **regrouper** les **individus**
- Indiquer comment les **associations individus /variables**

Avant tout, c'est une méthode **graphique**

Les associations entre variables

Le cercle des corrélations (ou loading plot)

- Le lien entre les composantes principales et les variables initiales est leur **corrélation**, que l'on trouve dans la « loading matrix ».
- On représente graphiquement les variables en fonction de leur corrélation avec les composantes principales.
- Le fait de mettre un cercle et des flèches est une tradition qui n'apporte rien ...




Les associations entre variables

```
# Cercle des corrélations : fviz_pca_var()
```



```
fviz_pca_var(ACP, repel=TRUE) # par défaut, le graphe est réalisé sur  
les axes 1 et 2
```

évite la juxtaposition du texte



Les associations entre variables

```
fviz_pca_var(ACP, axes=c(1,3), repel=TRUE) # Composantes 1 et 3
fviz_pca_var(ACP, axes=c(2,3), repel=TRUE) # Composantes 2 et 3
```



L'interprétation nous indique les **liens variable/composante** (par les corrélations), mais aussi **variable/variable** (variables proches sur le cercle).

Rappel : les composantes sont toujours indépendantes.

Donner une **signification aux composantes** (les axes) est le **but de l'ACP**.

Les variables


❖ Il est possible d'accéder à tous les résultats pour les variables actives : `get_pca_var()`

- Coordonnées (corrélations) entre les variables et les axes

```
var = get_pca_var(ACP)
var$coord
```

```
var$coord
```

##		Dim.1	Dim.2	Dim.3
##	Temp	0.13440894	-0.32423852	0.85482499
##	Flow	-0.38025323	-0.51486044	-0.48854665
##	pH	-0.78864077	0.06565025	0.01391784
##	Cond	0.86869322	0.26489734	-0.20350832
##	Oxyg	-0.81414304	0.13347703	-0.19909184
##	Bdo5	0.94177253	-0.14453262	-0.10631767
##	Oxyd	0.92230184	-0.18617618	-0.08345699
##	Ammo	0.97805991	-0.08456393	-0.02961809
##	Nitr	-0.05680654	0.92042315	0.09602067
##	Phos	0.91956351	0.24028212	-0.06902389




Les variables

- ❖ Il est possible d'accéder à tous les résultats pour les variables actives : `get_pca_var( )`
 - Coordonnées (corrélations) entre les variables et les axes

```
var = get_pca_var(ACP)
var$coord
```

```
var$coord
```

##		Dim.1	Dim.2	Dim.3
##	Temp	0.13440894	-0.32423852	0.85482499
##	Flow	-0.38025323	-0.51486044	-0.48854665
##	pH	-0.78864077	0.06565025	0.01391784
##	Cond	0.86869322	0.26489734	-0.20350832
##	Oxyg	-0.81414304	0.13347703	-0.19909184
##	Bdo5	0.94177253	-0.14453262	-0.10631767
##	Oxyd	0.92230184	-0.18617618	-0.08345699
##	Ammo	0.97805991	-0.08456393	-0.02961809
##	Nitr	-0.05680654	0.92042315	0.09602067
##	Phos	0.91956351	0.24028212	-0.06902389



- ❖ **Les variables corrélées négativement sont positionnées de part et d'autre de l'origine du plan factoriel**

Les variables


- ❖ Il est possible d'accéder à tous les résultats pour les variables actives : `get_pca_var( )`
 - Coordonnées (corrélations) entre les variables et les axes

```
var = get_pca_var(ACP)
var$coord
```

```
var$coord
```

##		Dim.1	Dim.2	Dim.3
##	Temp	0.13440894	-0.32423852	0.85482499
##	Flow	-0.38025323	-0.51486044	-0.48854665
##	pH	-0.78864077	0.06565025	0.01391784
##	Cond	0.86869322	0.26489734	-0.20350832
##	Oxyg	-0.81414304	0.13347703	-0.19909184
##	Bdo5	0.94177253	-0.14453262	-0.10631767
##	Oxyd	0.92230184	-0.18617618	-0.08345699
##	Ammo	0.97805991	-0.08456393	-0.02961809
##	Nitr	-0.05680654	0.92042315	0.09602067
##	Phos	0.91956351	0.24028212	-0.06902389

- ❖ **Les variables positivement corrélées sont regroupées**




Faciliter l'interprétation des variables : les rotations


Cela consiste à faire une rotation du cercle des corrélations, pour faciliter l'interprétation. Le pourcentage de variance expliqué pour chaque CP change ; ce n'est pas grave à ce stade.

```
### Rotation Varimax
ACP.rot = ACP
ACP.rot[["co"]] = varimax(as.matrix(ACP.rot$co))$loadings
fviz_pca_var(ACP, axes=c(2,3), repel=TRUE) # sans rotation
fviz_pca_var(ACP.rot, axes=c(2,3), repel=TRUE) # avec rotation
```

Sans rotation



Avec rotation : lien courant/Nitrate



Les associations entre individus

Grâce aux vecteurs propres, on peut calculer les **coordonnées des individus dans les composantes principales**.


Il n'y a plus qu'à faire des nuages de points en prenant les composantes deux par deux.

```
fviz_pca_ind(ACP, repel=TRUE) # Composantes 1 et 2 par défaut
```

```
fviz_pca_ind(ACP, axes=c(1,3), repel=TRUE) # Composantes 1 et 3
```

```
fviz_pca_ind(ACP, axes=c(2,3), repel=TRUE) # Composantes 2 et 3
```

**Exemple pour
les CP 1 et 2**



Les associations entre individus

Ce n'est pas très lisible ; on peut créer des **regroupements graphiques**.
Il est possible de faire les analyses habituelles (anova, régression) sur les résultats.

```
# Si on peut classer les individus, l'interprétation est facilitée ; ici, on peut
mettre les saisons
Saisons = meau$design$season
```

Dans la fonction **fviz_pca_ind()**, on superpose le facteur avec l'argument **col.ind = ...**

Exemple dans les composantes 1 et 3, où le facteur Saisons, lié à la température, apparaît clairement

```
fviz_pca_ind(ACP,
  axes=c(1,3),
  col.ind=Saisons,
  repel=TRUE,
  palette=c(1:4),
  addelipses=TRUE,
  ellipse.type="convex",
  legend.title="Saisons")
```

→ Facteur de regroupement

→ Code couleur (ici 4 pour les 4 saisons)


→ Ajout d'une ellipse

→ Type de l'ellipse ; on peut aussi mettre `ellipse.type="confidence"` pour faire apparaître le centre de gravité et son intervalle de confiance

Les associations entre individus


Ce qu'on obtient est généralement assez informatif : effet saison sur l'axe 3 (température)

Individuals - PCA



Les associations entre individus

Et avec le centre de gravité



Les individus

- ❖ Comme pour les variables, il est possible d'accéder à tous les résultats pour les individus :
get_pca_ind()

```
ind = get_pca_ind(ACP)  
ind$coord
```


Principal Component Analysis Results for individuals

```
=====
```

	Name	Description
1	"\$coord"	"Coordinates for the individuals"
2	"\$cos2"	"Cos2 for the individuals"
3	"\$contrib"	"contributions of the individuals"

ANALYSES MULTIVARIEES

Objectif : mettre en évidence une structure dans un tableau d'individus/variables



Résumer l'information en minimisant la déperdition et repérer des dimensions "cachées"	Variables Numériques et/ou ordinales	Analyse en Composantes Principales (ACP)	Analyse en Coordonnées Principales (PCoA), Non-Metric Multidimensional Scaling (NMDS)
	Deux variables qualitatives	Analyse Factorielle des Correspondances (AFC)	
	Trois variables qualitatives ou plus	Analyse des Correspondances Multiples (ACM)	
Constituer des groupes d'individus aussi similaires que possible	Le nombre de groupes est fixé	Analyse typologique	
	Le nombre de groupes n'est pas fixé	Classification hiérarchique	

Maintenant à vous de jouer !!!